

Inferencia Batimétrica con PINNs

Federico Mosca

Resumen

La reconstrucción de la topografía del fondo a partir de mediciones superficiales constituye un problema inverso de interés en oceanografía, hidrología y geofísica. En este trabajo se estudia la inferencia batimétrica en flujos descritos por las ecuaciones de aguas someras mediante Redes Neuronales Informadas por la Física (*Physics-Informed Neural Networks*, PINNs). Para ello, se generan datos sintéticos resolviendo numéricamente las ecuaciones de aguas someras unidimensionales sobre una topografía compleja y se utilizan únicamente observaciones del campo de altura para entrenar la red. La metodología propuesta emplea dos redes neuronales acopladas: una destinada a aproximar los campos dinámicos de velocidad y altura, y otra encargada de reconstruir la topografía del fondo. El entrenamiento se realiza combinando información observacional con los residuos de las ecuaciones diferenciales que gobiernan el sistema, permitiendo incorporar conocimiento físico de manera explícita dentro del proceso de optimización. Los resultados muestran que la técnica es capaz de recuperar satisfactoriamente la geometría del fondo utilizando exclusivamente mediciones superficiales, incluso con una cantidad reducida de observaciones. Estos resultados sugieren que las PINNs constituyen una herramienta prometedora para abordar problemas de inferencia batimétrica a partir de observaciones parciales del flujo.

1. Introducción

El conocimiento de la topografía del fondo oceánico constituye un elemento fundamental para comprender numerosos procesos geofísicos. La batimetría influye en la circulación oceánica, la propagación de tsunamis y otros fenómenos que intervienen en la dinámica del sistema océano-atmósfera y, en consecuencia, en la capacidad predictiva de los modelos climáticos [1, 2, 3]. Sin embargo, a pesar de que los océanos cubren más del 70% de la superficie terrestre, sólo una fracción relativamente pequeña de sus fondos ha sido cartografiada con alta resolución [4].

La obtención de datos batimétricos presenta importantes desafíos logísticos y económicos. Los métodos directos, como los ecosondas monohaz y multihaz, proporcionan mediciones precisas pero requieren campañas marítimas costosas, mientras que técnicas remotas basadas en satélites o LIDAR ofrecen mayor cobertura espacial a expensas de una menor resolución o de restricciones asociadas a la profundidad y transparencia del agua [5]. En este contexto, la inferencia de la topografía submarina a partir de observaciones indirectas constituye una alternativa atractiva. En particular, los flujos descritos por las ecuaciones de aguas someras permiten relacionar la dinámica superficial con la forma del fondo, convirtiendo la reconstrucción batimétrica en un problema inverso de interés científico y práctico. Este marco resulta especialmente relevante para el estudio de fenómenos costeros y de gran escala, como las mareas y los tsunamis.

En este trabajo se explora el uso de Redes Neuronales Informadas por la Física (*Physics-Informed Neural Networks*, PINNs) para reconstruir la topografía del fondo en flujos de aguas someras simulados numéricamente utilizando únicamente observaciones del campo de altura. Las PINNs incorporan las ecuaciones físicas que gobiernan el sistema dentro del proceso de entrenamiento, lo que permite inferir variables no observadas y obtener soluciones físicamente consistentes [6, 7, 8]. Recientemente, este enfoque también ha sido aplicado a problemas de inversión basados

en las ecuaciones de aguas someras, permitiendo inferir simultáneamente la geometría del fondo y variables hidráulicas a partir de observaciones parciales del flujo [9]. Esta metodología ha demostrado resultados prometedores en diversos problemas inversos de la mecánica de fluidos y constituye una herramienta especialmente adecuada para abordar el problema de inferencia batimétrica considerado aquí. Para evaluar su desempeño, se estudian flujos unidimensionales descritos por las ecuaciones de aguas someras y generados mediante simulaciones numéricas. A partir de observaciones sintéticas del campo de altura, se entrena una PINN para reconstruir simultáneamente los campos dinámicos del flujo y la topografía del fondo. En las secciones siguientes se presenta el modelo físico empleado, la metodología de entrenamiento implementada y los resultados obtenidos, con el objetivo de analizar el potencial y las limitaciones de este enfoque para la reconstrucción batimétrica.

2. Métodos

2.1. Aguas poco profundas

Partiendo de las ecuaciones de Euler para un flujo incompresible [10], bajo la hipótesis de una superficie libre en la interfaz fluido-aire, condiciones de no deslizamiento en el fondo y una escala horizontal característica mucho mayor que la escala vertical característica (la altura del fluido en reposo medida desde el punto más bajo), pueden derivarse las ecuaciones de aguas someras (*Shallow Water*, SW) [11, 12], las cuales describen la dinámica de la superficie libre. En el caso unidimensional, estas ecuaciones se pueden escribir como

$$\frac{\partial u}{\partial t} + u \frac{\partial u}{\partial x} + g \frac{\partial h}{\partial x} = 0, \quad (1)$$

$$\frac{\partial h}{\partial t} + \frac{\partial}{\partial x} \left(u(h - h_b) \right) = 0, \quad (2)$$

donde $u(x, t)$ y $h(x, t)$ describen la velocidad y la altura de la superficie del fluido respectivamente, mientras que $h_b(x)$ es la topografía del suelo bajo el fluido. La utilidad de estas ecuaciones trasciende el estudio de las aguas poco profundas, ya que son ampliamente aplicables para modelar fenómenos donde las escalas respetan la relación descrita previamente (p.e. tsunamis, cuya extensión característica ronda entre los 100 km y 500 km, y se propagan sobre profundidades típicas de tan solo 4 km).

Es importante mencionar que en este trabajo se eligió trabajar en el caso unidimensional debido a dos razones. En primer lugar, porque su resolución numérica es sencilla y rápida sin la necesidad de acudir a un hardware potente. En segundo lugar, y al contrario que antes, la técnica central de este trabajo sí podría necesitar un poder computacional mucho más elevado cuando se trabaja con un sistema bidimensional. De esta manera, trabajando en el caso unidimensional se abaratan los tiempos y necesidades de cómputo, fomentando así la reproducibilidad y exploración de la técnica.

2.1.1. Resolución Numérica

Las simulaciones numéricas unidimensionales de las ecuaciones de aguas someras se realizaron mediante un esquema pseudoespectral [13] en un dominio periódico de longitud 2π , discretizado con 1024 puntos de grilla. La estabilidad numérica requiere que el paso temporal Δt satisfaga la condición CFL,

g	h_0	η_0	σ	$\sigma^{(1)}$	$\sigma^{(2)}$	$x_0^{(1)}$	$x_0^{(2)}$	$h_{b0}^{(1)}$	$h_{b0}^{(2)}$
5	0.2	5×10^{-5}	$\frac{1}{2}$	0.3	0.2	$\frac{\pi}{1,4}$	$\frac{\pi}{0,8}$	0.1	0.05

Tabla 1: Parámetros utilizados para las condiciones iniciales para h y u y la topografía h_b en la resolución de las ecuaciones de aguas someras unidimensionales

$$\Delta t < \frac{\Delta x}{c}, \quad (3)$$

donde $c \sim \sqrt{gh_0}$ es la velocidad característica de propagación de ondas en el régimen lineal de las ecuaciones de aguas someras. Para eliminar modos espurios originados por *aliasing*, se aplicó la regla de 2/3: luego de calcular las derivadas espaciales de un término no lineal mediante el esquema pseudoespectral, todos los modos con número de onda $k > N/3$ fueron anulados [14]. La integración temporal se realizó mediante un esquema de Runge–Kutta de segundo orden.

Las condiciones iniciales consistieron en un paquete de ondas gaussiano,

$$h(x, t = 0) = h_0 + \eta_0 \exp \left[- \left(\frac{x - x_0}{\sigma} \right)^2 \right], \quad (4)$$

$$u(x, t = 0) = \sqrt{\frac{g}{h_0}} \eta_0 \exp \left[- \left(\frac{x - x_0}{\sigma} \right)^2 \right]. \quad (5)$$

La topografía del fondo se definió como

$$h_b(x) = h_{b0}^{(1)} \exp \left[- \left(\frac{x - x_0^{(1)}}{\sigma^{(1)}} \right)^2 \right] + h_{b0}^{(2)} \exp \left[- \left(\frac{x - x_0^{(2)}}{\sigma^{(2)}} \right)^2 \right] + \sum_{j=0}^{60} A_j \sin(k_j x + \phi_j), \quad (6)$$

donde los números de onda k_j y las fases ϕ_j fueron seleccionados aleatoriamente a partir de distribuciones uniformes $\mathcal{U}_k[40, 100]$ y $\mathcal{U}_\phi[0, \pi]$, respectivamente. Las amplitudes A_j se eligieron aleatoriamente de modo que las longitudes de onda asociadas permanecieran dentro de un rango preestablecido. Los valores utilizados para todos los parámetros se resumen en la Tabla 1.

2.2. Implementación de la PINN

Las Redes Neuronales Informadas por la Física (*Physics-Informed Neural Networks*, PINNs) son redes neuronales cuyo entrenamiento se regulariza mediante los residuos de un sistema de ecuaciones diferenciales de interés [6, 15], en este caso las ecuaciones de aguas someras, Ecs. (1) y (2). Dentro de este marco, se utilizan redes neuronales —típicamente perceptrones multicapa completamente conectados— para parametrizar los campos relevantes como funciones de las coordenadas espaciales y temporales.

En este trabajo utilizamos dos redes separadas NN_1 y NN_2 . Una parametriza u y h tomando como entradas x y t , mientras que la otra parametriza h_b tomando únicamente x como entrada. Denotamos las salidas de las redes mediante $\hat{u}$, $\hat{h}$ y $\hat{h}_b$, y reservamos las variables sin sombrero para las soluciones de las ecuaciones de aguas someras, es decir, los datos de referencia utilizados para evaluar el método. En esta línea definimos los puntos de colocación observacionales $\Omega_{\text{obs}} = \{x_i, t_i\}_{i=1}^N$, y los puntos de colocación físicos $\Omega_{\text{phy}} = \{x_j, t_j\}_{j=1}^M$, los cuales se utilizan para evaluar




Figura 1: Diagrama esquemático del flujo de información utilizado durante el entrenamiento. La red NN_1 produce las estimaciones de los campos de altura y velocidad, $\hat{h}$ y $\hat{u}$, mientras que la red NN_2 genera la estimación de la topografía del fondo $\hat{h}_b$. Las cantidades $\hat{h}$, $\hat{u}$ y $\hat{h}_b$ intervienen conjuntamente en el cálculo del término físico $\mathcal{L}_{phy}$, mientras que únicamente $\hat{h}$ contribuye al término observacional $\mathcal{L}_{obs}$ mediante la comparación con los datos disponibles.

las redes previamente definidas. De esta forma ya podemos definir los dos términos $\mathcal{L}_{obs}$ y $\mathcal{L}_{phy}$ que dan lugar a la función de costo $\mathcal{L}$ a optimizar en el entrenamiento conjunto de ambas redes, la cual se define como

$$\mathcal{L} = \mathcal{L}_{obs} + \lambda_{phy}\mathcal{L}_{phy}, \quad (7)$$

donde el hiperparámetro λ_{phy} controla el peso que se le otorga al residuo físico respecto al observacional. Por su parte $\mathcal{L}_{obs}$ no es más que el error cuadrático medio entre las salidas $\{\hat{h}_i\}_{i=1}^N$ de NN_1 y las observaciones $\{h_i\}_{i=1}^N$, por lo que se define como

$$\mathcal{L}_{obs} = \frac{1}{N} \sum_{i=1}^N (h_i - \hat{h}_i)^2. \quad (8)$$

Por otro lado, $\mathcal{L}_{phy}$ es el residuo cuadrático medio de las ecuaciones diferenciales (1) y (2) al evaluarlas en las salidas $\{\hat{h}_j, \hat{u}_j\}_{j=1}^M$ de NN_1 y las salidas $\{\hat{h}_{bj}\}_{j=1}^M$ de NN_2 , es decir

$$\mathcal{L}_{phy} = \frac{1}{M} \sum_{j=1}^M \left[\left(\frac{\partial \hat{u}_j}{\partial t} + \hat{u}_j \frac{\partial \hat{u}_j}{\partial x} + g \frac{\partial \hat{h}_j}{\partial x} \right)^2 + \lambda_2 \left(\frac{\partial \hat{h}_j}{\partial t} + \frac{\partial}{\partial x} (\hat{u}_j (\hat{h}_j - \hat{h}_{bj})) \right)^2 \right] \quad (9)$$

$$= \mathcal{R}_1 + \lambda_2 \mathcal{R}_2, \quad (10)$$

donde el hiperparámetro λ_2 controla el peso relativo entre el residuo $\mathcal{R}_1$ respecto al residuo $\mathcal{R}_2$. El mapeo entre entradas y salidas de la red, y la información sobre en qué términos de $\mathcal{L}$ influyen estas últimas, se resume en el diagrama de la Figura 1.

Teniendo en cuenta las definiciones anteriores, la función de costo definida en (7) puede reescribirse entonces como

$$\mathcal{L} = \mathcal{L}_{obs} + \lambda_{phy}(\mathcal{R}_1 + \lambda_2 \mathcal{R}_2). \quad (11)$$

Con esta nueva expresión es más fácil explicar como fueron actualizados los hiperparámetros de balance λ_{phy} y λ_2 durante el entrenamiento. Siguiendo a [15], en cada época se ponderaron los gradientes de cada uno de los términos de la Ec. (11) según

$$\lambda_{\text{phy}}^{k+1} = (1 - \alpha)\lambda_{\text{phy}}^k + \alpha \frac{\langle \nabla_{\theta} \mathcal{L}_{\text{obs}}^k \rangle}{\langle \nabla_{\theta} \mathcal{R}_1^k + \lambda_2^{k+1} \nabla_{\theta} \mathcal{R}_2^k \rangle}, \quad (12)$$

$$\lambda_2^{k+1} = (1 - \alpha)\lambda_2^k + \alpha \frac{\langle \nabla_{\theta} \mathcal{R}_1^k \rangle}{\langle \nabla_{\theta} \mathcal{R}_2^k \rangle}, \quad (13)$$

siendo $\langle \cdot \rangle$ el valor medio de los gradientes respecto de los parámetros entrenables θ . Este procedimiento permite ajustar dinámicamente el peso relativo de cada término de la función de costo, evitando que alguno de ellos domine el proceso de optimización y favoreciendo un entrenamiento más equilibrado.

3. Resultados

La Figura 2 muestra capturas instantáneas de los campos de velocidad $u(x, t)$ (panel izquierdo) y altura $h(x, t)$ (panel derecho) para el instante inicial $t = 0$ y para dos tiempos posteriores. En todos los casos, las soluciones obtenidas mediante la simulación numérica se representan en azul, mientras que las predicciones de la red neuronal NN_1 se muestran en rojo mediante los campos estimados $\hat{u}(x, t)$ y $\hat{h}(x, t)$. Puede observarse que la condición inicial dada por la Ec. (5) se deforma progresivamente a medida que la onda se propaga sobre la topografía del fondo definida por la Ec. (6). La interacción con las irregularidades del fondo modifica tanto la forma del campo de altura como la del campo de velocidades, generando estructuras cada vez más complejas a medida que transcurre el tiempo.

Al comparar las soluciones simuladas con las aproximaciones obtenidas por la red, se observa un excelente acuerdo para el campo de altura. En particular, $\hat{h}(x, t)$ reproduce con gran precisión la evolución temporal de $h(x, t)$ para los tres instantes considerados. El comportamiento del campo de velocidades es ligeramente diferente. Si bien $\hat{u}(x, t)$ captura correctamente la forma general y la curvatura de $u(x, t)$, se aprecia un desplazamiento aproximadamente constante entre ambas curvas. Este comportamiento puede entenderse a partir de la estructura de la función de costo utilizada durante el entrenamiento. Los términos físicos que intervienen en $\mathcal{L}$ dependen únicamente de derivadas espaciales y temporales de $\hat{u}$. En consecuencia, sumar una constante arbitraria al campo de velocidades no modifica los residuos de las ecuaciones diferenciales y, por lo tanto, tampoco altera el valor de la función de costo. Desde el punto de vista del problema de optimización, existe entonces una familia de soluciones equivalentes que difieren únicamente en una constante aditiva. Esto explica por qué la red puede converger a una aproximación de u desplazada respecto de la solución simulada sin que ello represente una violación de las ecuaciones físicas. De hecho, al reiniciar el entrenamiento es esperable que el valor de dicho corrimiento cambie de una realización a otra. Por el contrario, esta indeterminación no aparece en el campo de altura. Debido a la presencia del término observacional $\mathcal{L}_{\text{obs}}$ en la función de costo, la red es penalizada directamente cuando sus predicciones se apartan de las observaciones disponibles de h . Como resultado, la estimación $\hat{h}$ queda anclada a los datos y no presenta desplazamientos arbitrarios respecto de la solución de referencia.

Pasando ahora al objetivo principal de este trabajo, la reconstrucción de la topografía del fondo, la Figura 3 muestra la evolución temporal de la estimación batimétrica $\hat{h}_b$ obtenida mediante la red NN_2 . Se presentan resultados para dos configuraciones experimentales distintas, correspondientes a $N = 1$ y $N = 16$ puntos observacionales. En ambos casos se observa que la reconstrucción mejora de manera sistemática a medida que avanza el entrenamiento. Durante las primeras etapas, la estimación de la topografía presenta diferencias significativas respecto del




Figura 2: Comparación entre los campos simulados (azul) y las predicciones de la red neuronal NN_1 (rojo) para la velocidad $u(x, t)$ (izquierda) y la altura superficial $h(x, t)$ (derecha) en tres instantes de tiempo. La red reproduce con gran precisión la evolución temporal del campo de altura y captura adecuadamente la estructura espacial del campo de velocidades, presentando únicamente un corrimiento aproximadamente constante.

perfil verdadero. Sin embargo, conforme disminuye la función de costo, la red incorpora progresivamente la información contenida tanto en las observaciones como en las ecuaciones físicas, logrando aproximaciones cada vez más precisas de la batimetría.

La comparación entre los casos $N = 1$ y $N = 16$ muestra que una mayor cantidad de observaciones acelera el proceso de aprendizaje. En particular, luego de aproximadamente 100 épocas, la reconstrucción obtenida con $N = 16$ ya reproduce de manera más fiel la topografía verdadera que la obtenida con $N = 1$. Este comportamiento resulta esperable, ya que un mayor número de observaciones proporciona más información sobre el sistema y vuelve a la función de costo más sensible a discrepancias entre las predicciones de la red y los datos disponibles.

No obstante, una observación interesante es que esta ventaja inicial no se mantiene necesariamente durante todo el entrenamiento. Hacia las 700 épocas ambas configuraciones producen reconstrucciones satisfactorias de la topografía del fondo, lo que indica que la metodología es capaz de converger a soluciones útiles incluso cuando la cantidad de datos observacionales es extremadamente reducida. Más aún, en esta etapa del entrenamiento la reconstrucción correspondiente a $N = 1$ parece presentar un acuerdo mejor con la topografía de referencia que la obtenida con $N = 16$, lo cual fue un resultado inesperado. Esto último sugiere que la relación entre cantidad de observaciones y calidad final de la reconstrucción no es necesariamente trivial. Factores como la inicialización aleatoria de los pesos, la complejidad del paisaje de optimización y el balance relativo entre los distintos términos de la función de costo pueden influir significativamente en la trayectoria seguida durante el entrenamiento. En cualquier caso, los resultados muestran que la técnica propuesta es capaz de recuperar con éxito la estructura principal de la topografía del fondo utilizando únicamente observaciones superficiales del flujo.




Figura 3: Evolución de la reconstrucción batimétrica $\hat{h}_b$ obtenida mediante la red NN_2 a distintas etapas del entrenamiento. La línea gris representa la topografía de referencia utilizada en las simulaciones, mientras que las curvas de colores corresponden a las estimaciones de la red para diferentes números de épocas. Se muestran los casos con $N = 1$ y $N = 16$ puntos observacionales. En ambos casos la reconstrucción converge progresivamente hacia la topografía verdadera a medida que avanza el entrenamiento.

4. Discusión y Conclusiones

En este trabajo se estudió la aplicación de Redes Neuronales Informadas por la Física (*Physics-Informed Neural Networks*, PINNs) al problema de reconstrucción batimétrica en flujos descritos por las ecuaciones de aguas someras. Utilizando únicamente observaciones del campo de altura superficial, se entrenó una arquitectura compuesta por dos redes neuronales: una destinada a aproximar los campos dinámicos del flujo y otra encargada de inferir la topografía del fondo. Los resultados obtenidos muestran que la metodología es capaz de recuperar satisfactoriamente la estructura general de la batimetría a partir de información superficial únicamente. A medida que avanza el entrenamiento, las estimaciones de la topografía convergen progresivamente hacia el perfil de referencia, reproduciendo tanto las variaciones de gran escala como los rasgos más relevantes de la geometría del fondo. Este comportamiento constituye una evidencia de que la información contenida en las observaciones de altura, combinada con las restricciones físicas impuestas por las ecuaciones de aguas someras, resulta suficiente para inferir variables que no son observadas de manera directa.

Asimismo, se verificó que la red encargada de aproximar los campos dinámicos reproduce con gran precisión la evolución temporal de los campos de altura y velocidad del fluido. En el caso del campo de velocidades, las predicciones presentan un corrimiento aproximadamente constante respecto de la solución de referencia. Sin embargo, este comportamiento no debe interpretarse como una falla del método, sino como una consecuencia de la propia formulación del problema. Dado que las ecuaciones diferenciales y los términos físicos de la función de costo dependen únicamente de derivadas de la velocidad, el problema posee una indeterminación aditiva que

permite desplazar el campo por una constante sin modificar los residuos físicos. La capacidad de la red para reproducir correctamente la forma y curvatura del campo de velocidades indica que la dinámica relevante del sistema ha sido capturada adecuadamente.

Existen numerosas líneas de trabajo futuro que permitirían profundizar el análisis presentado. Una primera dirección consiste en estudiar de manera sistemática la sensibilidad de las reconstrucciones frente a diferentes densidades de observación, niveles de ruido, arquitecturas neuronales e hiperparámetros de entrenamiento. Del mismo modo, sería interesante cuantificar la variabilidad entre distintas realizaciones del entrenamiento para determinar la robustez estadística de los resultados observados. Otra extensión natural consiste en reemplazar las condiciones iniciales idealizadas utilizadas en este trabajo por configuraciones más representativas de sistemas geofísicos reales. La utilización de perfiles de altura y velocidad más complejos, así como de topografías inspiradas en escenarios oceánicos o costeros reales, permitiría evaluar hasta qué punto la metodología conserva su capacidad de reconstrucción cuando se enfrenta a dinámicas significativamente más complejas que las consideradas aquí. En esta línea, extender el enfoque a configuraciones bidimensionales, aunque ello implicaría un incremento considerable en el costo computacional y en la complejidad del entrenamiento, permitiría abordar problemas más cercanos a aplicaciones reales y explorar el potencial de las PINNs como herramienta para la inferencia batimétrica en contextos de interés oceanográfico.

En conjunto, los resultados obtenidos muestran que las PINNs constituyen una herramienta prometedora para la reconstrucción de topografía submarina a partir de observaciones superficiales. La capacidad de combinar información observacional con conocimiento físico del sistema permite inferir magnitudes no medidas directamente y ofrece un marco flexible para abordar problemas inversos en mecánica de fluidos. Si bien aún son necesarios estudios más exhaustivos para caracterizar completamente sus alcances y limitaciones, el presente trabajo demuestra la viabilidad de esta metodología para la inferencia batimétrica en el contexto de las ecuaciones de aguas someras.

5. Datos y Software

Los datos utilizados en este trabajo no provienen de un dataset público, sino que fueron generados sintéticamente mediante la resolución numérica de las ecuaciones de aguas someras unidimensionales como se mencionó en la Sección 2, a partir de las condiciones iniciales y la topografía definidas en las Ecs. (5) y (6).

El código desarrollado para este proyecto, incluyendo tanto la simulación numérica como la implementación de la PINN, está disponible públicamente en https://github.com/fedemosca/PINN_SW. Las librerías de Python utilizadas y sus versiones se detallan en el archivo `requirements.txt` del repositorio.

Referencias

- [1] Jonathan Gula, M. Jeroen Molemaker, and James C. McWilliams. Gulf stream dynamics along the southeastern u.s. seaboard. *Journal of Physical Oceanography*, 45(3):690–715, 2015. doi: 10.1175/JPO-D-14-0154.1.
- [2] A. Santoso, W. Cai, M. H. England, and S. J. Phipps. The role of the indonesian throughflow on enso dynamics in a coupled climate model. *Journal of Climate*, 24(3):585–601, 2011. doi: 10.1175/2010JCLI3745.1.

- [3] Henri Degueldre, Jakob J. Metzger, Theo Geisel, and Ragnar Fleischmann. Random focusing of tsunami waves. *Nature Physics*, 12:259–262, 2016. doi: 10.1038/nphys3557.
- [4] Walter Smith, Karen Marks, and Thierry Schmitt. Airline flight paths over the unmapped ocean. *Eos Transactions American Geophysical Union*, 2017. doi: 10.1029/2017EO069127.
- [5] Anne-Cathrin Wölfl, Helen Snaith, Sam Amirebrahimi, Colin W. Devey, Boris Dorschel, Vicki Ferrini, Veerle A. I. Huvenne, Martin Jakobsson, Jennifer Jencks, Gordon Johnston, Geoffroy Lamarche, Larry Mayer, David Millar, Terje Haga Pedersen, Kim Picard, Anja Reitz, Thierry Schmitt, Martin Visbeck, Pauline Weatherall, and Rochelle Wigley. Seafloor mapping – the challenge of a truly global ocean bathymetry. *Frontiers in Marine Science*, 6, 2019. doi: 10.3389/fmars.2019.00283.
- [6] Maziar Raissi, Paris Perdikaris, and George E. Karniadakis. Physics informed deep learning (part i): Data-driven solutions of nonlinear partial differential equations. *CoRR*, abs/1711.10561, 2017.
- [7] S. Cai, Z. Mao, and Z. Wang. Physics-informed neural networks (pinns) for fluid mechanics: a review. *Acta Mechanica Sinica*, 37:1727–1738, 2021. doi: 10.1007/s10409-021-01148-1.
- [8] Salvatore Cuomo, Vincenzo Schiano Di Cola, Fabio Giampaolo, Gianluigi Rozza, Maziar Raissi, and Francesco Piccialli. Scientific machine learning through physics-informed neural networks: Where we are and what’s next. *Journal of Scientific Computing*, 92(3):88, 2022. doi: 10.1007/s10915-022-01939-z.
- [9] Y. Ohara, D. Moteki, S. Muramatsu, K. Hayasaka, and H. Yasuda. Physics-informed neural networks for inversion of river flow and geometry with shallow water model. *Physics of Fluids*, 36(10):106633, 2024. doi: 10.1063/5.0232852.
- [10] L.D. Landau and E.M. Lifshitz. *Fluid Mechanics*. Course of Theoretical Physics. Pergamon Press, 1987. ISBN 0080339336.
- [11] J. Pedlosky. *Geophysical Fluid Dynamics*. Springer Verlag, 1987. ISBN 354096388X, 9783540963882.
- [12] G. B. Whitham. *Linear and nonlinear waves*. John Wiley & Sons, 1974. ISBN 1118031202, 9781118031209.
- [13] David Gottlieb and Steven A. Orszag. *Numerical Analysis of Spectral Methods: Theory and Applications*. Society for Industrial and Applied Mathematics, 1977. ISBN 9780898710236.
- [14] Steven A. Orszag. Comparison of pseudospectral and spectral approximation. *Studies in Applied Mathematics*, 51(3):253–259, 1972. doi: 10.1002/sapm1972513253.
- [15] S. Wang, Y. Teng, and P. Perdikaris. Understanding and mitigating gradient flow pathologies in physics-informed neural networks. *SIAM Journal on Scientific Computing*, 43(5):A3055–A3081, 2021. doi: 10.1137/20M1318043.